

# Sürüş Ortamında Sürücü Uykuluk Tespitinin Derin Öğrenme Yöntemleri Kullanarak Gerçekleştirilmesi

## Detection of Driver Drowsiness in Driving Environment using Deep Learning Methods

Vedat Tümen<sup>1</sup>, Özal Yıldırım<sup>1</sup>  
Bilgisayar Mühendisliği Bölümü  
Munzur Üniversitesi  
Tunceli, Türkiye  
{vtumen, oyildirim}@munzur.edu.tr

Burhan Ergen<sup>2</sup>  
Bilgisayar Mühendisliği Bölümü  
Fırat Üniversitesi  
Elazığ, Türkiye  
bergen@firat.edu.tr

**Özetçe—** Bu çalışmada, sürücülerin sürüş ortamındaki uyku durumlarının tespiti için derin öğrenme yöntemi kullanılmıştır. Sürücülere ait belirli hareketsiz yüz görüntülerindeki gözlerin kapalı olup olmadığının tespit edilmesi için bir konvolüsyonel sinir ağı (KSA) modeli önerilmiştir. Önerilen bu model, insan-bilgisayar arayüz tasarımı, yüz ifadesi tanıma, sürücü yorgunluğunun-uykuluğunun tespit edilmesi gibi geniş bir potansiyel uygulama alanına sahiptir. Sürücü uykuluk tespiti verileri üzerinde geliştirilen bu yöntem Closed Eyes In The Wild (CEW) verisetinde bulunan 4.846 adet gerçek yüzdeki göz imgeleri üzerinde uygulanmıştır. Hazırlanan modelin başarımlarını kıyaslamak için aynı veriler üzerinde, yaygın kullanılan KSA modelleri kullanılmıştır. Elde edilen sınıflandırma sonuçlarına göre, tasarlanan modelin 96.5% ve 92.99% düzeyinde başarıya ulaştığı ve bu problem alanında kullanılabilecek bir yapı olduğu görülmektedir.

**Anahtar Kelimeler —**sürücü uyku tespiti; konvolüsyonel sinir ağları; görüntü işleme.

**Abstract -** In this study, a deep learning method was used to detect sleep states of the drivers in the driving environment. A convolutional neural network (CNN) model has been proposed to determine whether the eyes of certain constant face images of drivers are closed. The proposed model has a wide potential application area such as human-computer interface design, facial expression recognition, driver fatigue-sleepiness determination. This method, which was developed on driver sleepiness data, has been applied on 4,846 real eye images in the Closed Eyes In The Wild (CEW) database. Commonly used CNN models are used on the same data to compare performances of the prepared model. According to the classification results obtained, 96.5% and 92.99% of the designed model achieved success and it is seen that this structure can be used in this problem area.

**Key words -** driver drowsiness detection; convolutional neural networks; image processing.

### I. GİRİŞ

Göz kapallığı tespiti, gerçek dünya uygulama senaryosunda; parlaklık, bulanıklık, farklı cilt rengi gibi bireysel farklılıklardan ve ortam değişikliklerinin çeşitliliğinden kaynaklanan zorlayıcı koşullar içeren karmaşık bir işlemdir. Göz kapallığının tespiti bir çok alanda uygulama imkanı bulmuştur. Bunların başında son zamanlarda; sürücü destek sistemleri, akıllı araçların geliştirilmesi ve iyileştirilmesi, sürücü kontrol ve uyarı sistemleri gibi birçok alan bulunmaktadır. Bilişim çağındaki gelişmeler paralelinde yapay zekanın tüm alanlara uyarlanması ve gelişimi ile günümüzde sürücüsüz hareket eden araçlar üretilmektedir. Bu alandaki araştırmalar devam ederken sürücü destek sistemleri için ihtiyaca göre farklı çözümler de üretilmektedir. Sürücüsüz araç üreticileri Google, Toyota, Nissan, BMW, Tesla gibi üreticiler, sürücü destek sistemleri teknolojileri üzerinde ARGE faaliyetlerini sürdürmektedirler [1]. Günümüzdeki sürücü destek sistemleri incelendiğinde çok farklı alanlarda çalışmalar yapıldığı görülmektedir.

Sürekli hareket halinde olan araç trafiği; yol, araç ve insan etkileşimlerinden oluşmakta ve bunlardan herhangi birinde oluşabilecek aksaklık hayati kazalara sebep olmaktadır [2]. TÜİK (Türkiye İstatistik Kurumu), 2009-2016 yılları arasında meydana gelen trafik kazalarındaki sürücü hataları 89.3% olarak açıklamıştır [3]. ABD NHTSA (National Highway Traffic Safety Administration) araştırmasına göre ABD'deki ölüm veya yaralanma ile sonuçlanan 56.000 trafik kazalarına sürücülerin uyku halinin sebep olduğu belirtilmiştir [4].

### II. İLGİLİ ÇALIŞMALAR

Sürücü yorgunluk-uykululuk tespiti için farklı tipte çalışmalar mevcuttur. Bu çalışmalar, vücut sıcaklık değerleri, nabız değerleri veya beyin elektriksel sinyallerinin elde edilmesi ile sürücünün uyanıklık durumu hakkında bilgi vermektedir [5]. Fiziksel vücut özelliklerinin incelenmesiyle yapılan çalışmalar EEG (Electroencephalography) başlığı gibi yardımcı aparatlar gerektirdiği için sürücüyü rahatsız etmekte ve gerçek hayatta uygulanması sürücüler için zordur. Bir diğer çalışma [6] ise sürücünün kullandığı aracın verdiği tepkilerin algılanmasına

yönelik yapılmış olup, günümüzde araçlarda kullanılan yorgunluk tespit sistemleri bu parametrelere bağlı olarak geliştirilmiştir. Bu parametreler aracın gaz pedalı ve direksiyonu gibi araç donanımına yerleştirilen sensörlerden anlık olarak elde edilip, sürüş tipi ve sürücü durumunun tespit edilmesinde kullanılmaktadır [6]. Bu tip çalışmalar genelde sürücü özelliklerine göre büyük farklılık göstermekte ve buna bağlı olarak başarı oranı düşük olmaktadır. Bunun yanı sıra, sensörlerin aracın istenen konumlarına yerleştirilmesi zahmetli ve uzman gerektiren işlemlerdir. Aynı zamanda bu sistemler, bakım – onarım gerektiren süreçler içermektedir.

Gözün kapalı olup olmadığı ya da sürücülerin uykulu olup olmadığı tespiti ile ilgili literatürde birçok çalışma bulunmaktadır. Sürücü uyanıklık tespiti için geliştirilen başka bir yöntem ise sürücüye ait görüntülerin anlık olarak tespit edilmesi ve değerlendirilmesi ile sürücünün durumunun belirlenmesine dayanır [7]. Sürücünün verdiği uyarının algılanmasına dayanan sistemler genellikle sürücü yorgunluğu seviyesi tespiti için arabaya yerleştiren kameradan sürücü görüntüsünü alıp sürücü yorgunluk seviyesini tespit etmeye çalışır. PERCLOS (Percentage of eye closure) sürücü uykuyorgunluk seviyesi tespiti için en çok kullanılan parametre bileşenleridir [8]. Göz kapanma oranını belirleyen PERCLOS, belli bir sürede gözün 80% kapalı olduğu zamanın oranını ifade etmek için kullanılmaktadır. Gözün kapalı ve açık olma durumunun tespiti, yorgunluk-uykusuzluk algılama ve kameralar ile göz kırpması sistemi dahil olmak üzere geniş uygulamalara sahiptir.

Luis M. Bergasa ve arkadaşlarının yapmış olduğu [9] çalışmada, sürücünün uyanıklık hali gerçek zamanlı olarak izlenmiş ve yüzde göz kapanışı süresi, göz kırpması sıklığı gibi parametreler tespit edilerek bulanık sınıflandırma ile yüksek başarımla elde edilmiştir. Fengi Song ve ark. [10] yapmış oldukları çalışmalarında, yüz görüntüsünde gözlerin kapalı olup olmadığını tespit etmeye yönelik olarak farklı görüntü işleme tekniklerini ZJU ve CEW veritabanı üzerinde farklı sınıflandırma yöntemleri ile test etmiş ve başarımları karşılaştırmıştır. Brojeshwar Bhowmick ve ark. [11] çalışmalarında, sürücü uykusuzluğunu belirlemek için göz tespiti ve gözün açık-kapalı olma durumunu doğrusal olmayan destek vektör makineleri (DVM) sınıflandırıcısı kullanarak tespit etmişlerdir. Xue Liu ve ark. [12] çalışmalarında, kapalı göz tespiti için farklı sınıflandırma teknikleri kullanmış ve en yüksek başarımla DVM+HOG yöntemi ile elde etmiştir.

Yapılan çalışmaların çoğunun belirli veritabanları üzerinde yapıldığı ve bunların başarımlarının karşılaştırılması şeklinde olduğu görülmektedir. Bu çalışmalarda; SVM, k-NN, AdaBoost gibi sığ yapı sınıflandırıcıların kullanıldığı görülmektedir. Bu çalışmada kamuya açık olarak paylaşılan CEW veritabanındaki görüntülerde bulunan açık ve kapalı göz imgeleri ile sığ-yapılı öğrenme yöntemlerinin yerine hem özellik çıkarımı hem de sınıflandırma süreçlerini bir arada barındıran bir derin öğrenme yöntemi önerilmiştir.

### III. DERİN ÖĞRENME

Günümüzde oldukça popüler bir alana dönüşen derin öğrenme, çok katmanlı ileri beslemeli sinir ağlarının eğitilme süreçlerinin bir araya gelmesi ile meydana gelmektedir. Derin öğrenme modelleri çok sayıda farklı nitelikte gizli katman ile oluşturulduğundan bu ismi almıştır. Görüntü sınıflandırma, tanımlama, bölme-ayırma, video analizi ve anlamlandırma, sınıflama, ses tanıma ve işleme, doğal dil öğrenme gibi birçok farklı alanda kullanılmaktadır. Derin öğrenme özellikle, büyük miktarlarda, etiketlenmemiş eğitim verilerinden öznelik çıkarım yöntemleri ile özelliklerin saptamasını yapabilen

sistemler oluşturmak için ileri teknoloji, çok seviyeli sinir ağların kullanılması ile oluşmaktadır.

Günümüzde halen kullanılan yapay sinir ağlarının tek başına bazı problemleri çözmede yetersiz kalması veya sonuçların geç üretilmesi, verilerin daha ileri bir seviyede işlenmesi için derin öğrenme algoritmaları-modelleri geliştirilmektedir. Derin öğrenme alanında özellikle görüntü işlemede, görüntüyü bütün olarak işleyen ve verinin özneliklerinin elde edilmesi ile sınıflara veya özelliklerine ayıran, başarımları yüksek olan konvolüsyon sinir ağları yöntemi kullanılmaktadır.

#### A. Konvolüsyonel Sinir Ağları

Teknolojinin gelişimine paralel olarak artan veri boyutu ile oluşan büyük verilerden tutarlı ve anlamlı bilgileri çıkarmak, özellik çıkarımı ile ilgili optimizasyon yapmamızı sağlamıştır. Klasik yapay sinir ağları, nöronlar ve gizli katmanlar arasındaki ilişkiler ve öğrenilen parametreler çok büyük hesaplama gerektirmekte ve hem zaman hem de maliyet açısından dezavantajlıdır. 1990 yılında Yann LeCun tarafından aslında rakam tanıma için geliştirilen ve günümüzde artan bir şekilde kullanılan KSA'lar, çok katmanlı sinir ağlarının ileri yayılım algoritmasının özel bir türüdür [13]. KSA, ön işlem aşamasını minimum düzeye indirgeyerek; kenar, kalıp ve temel özelliklerin ortaya çıkartılması için geliştirilmiştir. KSA'nın, öznelik çoğaltma ve özetleme katmanlarına sahip olması, diğer sınıflandırma, tanıma algoritmalarına göre daha iyi sonuçlar üretmektedir.

Günümüzde oldukça popüler olan ve halen kullanılan KSA tabanlı ve KSA türevli modeller, LeNet [14], AlexNet [15], GoogLeNet [16], VGGNet [17] ve ResNet [18]'tir. KSA katmanları modellere göre değişim ve gelişim farklılıkları göstermekte ve temel olarak dört katmandan oluşmaktadır.

1) *Konvolüsyon katmanı*: Konvolüsyon katmanı nöronlardan oluşan ve genelde rastgele sayılardan üretilen ağırlık filtreleri ve özellik haritalarından oluşmaktadır. Bu ağırlıklar ile imgenin tüm kanallardaki piksel değerleri belli aralıklarla konvolüsyon işlemine tabi tutulur ve yeni bir çıktı elde edilir.

2) *Pooling katmanı*: Konvolüsyon katmanından sonra oluşan verilerdeki hesaplama karmaşıklığını azaltmak için kullanılan bir adımdır. Ancak verilerdeki önemli bazı bilgilerin kaybolmasına sebep olabilir. Pooling katmanında genelde maksimum ve ortalama teknikleri yaygın olarak kullanılır. Maksimum pooling katmanı, filtrelemeden sonra seçilen bölgedeki piksellerin en büyük değerini çıkış olarak seçer.

3) *Aktivasyon katmanı*: Bu katmanda hazırlanan farklı doğrusal olmayan aktivasyon fonksiyonları, verilere uygulanarak eşik değerden geçirilir. KSA modellerinde kullanılan en yaygın yöntem sıfıra eşikleme olarak bilinen ve Denklem 1'de ifade edilen ReLU aktivasyon fonksiyonudur.

$$ReLU: f(x) = \begin{cases} 0; & x \leq 0 \\ x; & x > 0 \end{cases} \quad (1)$$

Bu yöntem, sigmoid ve tanjant fonksiyonu ile karşılaştırıldığında daha hızlı sonuç üretmektedir. ReLU yönteminin yanı sıra birçok aktivasyon fonksiyonu bulunmaktadır. Bunlardan bazıları;

$$0/1 \text{ step} : f(x) \begin{cases} 0; x \leq 0 \\ 1; x > 0 \end{cases} \quad (2)$$

$$-1/+1 \text{ step} : f(x) \begin{cases} 0; x \leq 0 \\ -1; x > 0 \end{cases} \quad (3)$$

$$\text{Sigmoid} : f(x) = \frac{1}{1 + e^{-x}} \quad (4)$$

$$\tanh : f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (5)$$


4. *Softmax sınıflandırıcı katmanı*: Özellikle yüksek sayıda farklı etiketli verilerin sınıflandırılması için kullanılan başarılı bir yöntemidir. İşleme sonucunda verinin parametreleri en çok hangi sınıfa benzerlik gösteriyorsa o sınıfa ayırır.

#### IV. DENEYSEL SONUÇLAR

Bu makale çalışmasında, iki ayrı deneysel çalışma yapılmıştır. Bunlardan birincisinde, CEW veritabanından alınan göz görüntüleri sol ve sağ göz şeklinde ayrılarak sınıf sayısı artırılmış ve dört sınıflı bir veri seti hazırlanmıştır. İkinci çalışma ise yine aynı veritabanındaki imgeler açık göz ve kapalı göz olarak iki sınıfa ayrılmıştır. Her iki çalışmada da KSA tabanlı modeller kullanılmış ve başarımları değerlendirilmiştir.

##### A. Veritabanı

Bu çalışma, kamuya açık olarak paylaşılan Closed Eyes In The Wild (CEW) [19] sisteminde bulunan CEW veritabanında farklı ışık ortamı altında elde edilmiş açık ve kapalı göz imgeleri kullanılmıştır. Şekil 1'de, görüldüğü gibi rastgele seçilmiş dört sınıflı etikete sahip imgelerin bir kısmı verilmiştir.




Şekil 1. CEW veritabanında bulunan örnek imgeler(a: sol-kapalı, b: sağ-kapalı, c: sağ-açık, d: sağ-açık)

CEW veritabanı içerisinde; 1192 kişiye ait kapalı göz imgesi ve 1231 kişiye ait açık göz imgeleri bulunmaktadır. Verisetindeki imgeler 24x24 boyutlu ve gri formatta oluşturulmuştur. Bu imgeler kapalı-açık sol-sağ göz şeklinde etiketlenmiştir. Veriseti üzerinde yapılan birinci çalışmada, dört sınıf (sol-kapalı, sol-açık, sağ-kapalı, sağ-açık) kullanılmıştır. İkinci çalışmada ise sol ve sağ gözlerin birleştirilmesi ile elde edilen iki sınıf (açık ve kapalı göz) kullanılmıştır. Her iki çalışma için veritabanının 80%'i eğitim, 20%'si ise test aşamasında kullanılmak üzere ayrı veri setleri oluşturulmuştur.

##### B. Çalışma Ortamı ve Kullanılan Donanım

Sınıflandırma işlemi için Python programla dili kullanılmış ve sınıflandırma katmanı olarak softmax sınıflandırıcısı olan KSA tabanlı modeller tasarlanmıştır. Deneysel çalışmalar, CPU tabanlı olarak Intel Xenon 2.20 GHz işlemci ve GPU Tesla K80 donanımı üzerinde yapılmış ve her iki donanıma ait performanslar değerlendirilmiştir. Önerilen KSA modelinin performans kıyaslamaları için; Lenet\_5, Vgg\_5, Vgg\_6, Vgg\_7 modelleri, veritabanında bulunan imgelere uygulanmıştır. Şekil 2'de göz kapalılığı tespiti için hazırlanan toplamda 13 katmanlı KSA tabanlı sınıflandırma modeli sunulmuştur.



Şekil 2. Göz kapalılığı tespiti için hazırlan KSA modeli.

Önerilen KSA modeli, ilk katmanda 24x24 boyutlu gri formatında imgeleri giriş olarak almakta ve bu katman üzerinde 3x3 boyutlu filtreler ile özellik haritaları elde edilmektedir. Konvlüsyon katmanından sonra gelen ReLU aktivasyon katmanı ile özellik haritaları eşiklenmektedir. ReLU katmanının çıkışı tekrar bir konvolüsyon katmanına verilmiş ardından bu veriler farklı kernel boyutu ile filtreden geçirildikten sonra ReLU aktivasyon katmanına verilmiştir. Bu işlem aynı şekilde tekrar edildikten sonra verilerdeki ayrıntıların belirgin hale getirilmesi ve boyut küçültme için Max Pooling katmanı kullanılmıştır. Bu işlemler birkez daha tekrar edildikten sonra Tam Bağlı katmanından geçirilmiş ve son olarak oluşan tüm bu hücreler softmax sınıflandırıcı katmanı ile sınıflandırılmıştır.

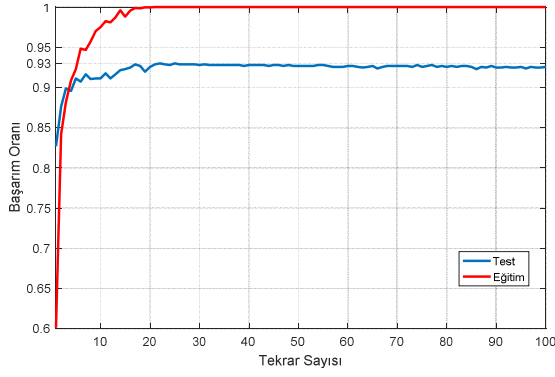
##### C. Deneysel Çalışma 1

Bu çalışmada, veritabanında bulunan etiketlenmiş göz imgeleri, dört sınıf olarak KSA tabanlı modeller altında sınıflandırılmış ve başarımları test edilmiştir. Tablo 1'de dört sınıfa göre KSA modellerinin başarımları görülmektedir.

Tablo 1. KSA modellerinin dört sınıfı tanımadaki başarımları.

KSA Modelleri	Aşama (epoch) (100)	Her periyotta Geçen süre (sn) GPU/CPU	Başarım Oranı(%)
Lenet_5	92	2/16	92.16
Vgg_5	94	2/18	92.27
Vgg_6	88	3/18	92.47
Vgg-7	65	3/21	92.37
<b>Önerilen KSA Modeli</b>	<b>22</b>	<b>1/14</b>	<b>92.99</b>

Tablo 1 incelendiğinde hazırlanmış olduğumuz modelin başarımlarının diğer modellere göre yüksek olduğu aynı zamanda eğitim sürecinin daha erken sonuçlandığı ve en yüksek başarıya 22. aşamada ulaştığı görülmektedir. Şekil 3'te modelimizin 0-100 devirdeki başarımlar grafiği görülmektedir.



**Şekil 3.** KSA modelinin 4 sınıflı görüntüler üzerinde eğitim ve doğrulama sonuçları.

Şekil 3 incelendiğinde; 22. aşamada modelin 92.99% başarı elde ettiği ve bu aşamada eğitim aşamasının tamamlanmış olduğu görülmektedir. İncelenen diğer modellerin hem bu başarıya ulaşmadığı hem de eğitim aşamasının biraz daha uzun sürdüğü görülmüştür.

#### D. Deneysel Çalışma 2

Bu çalışmada, veritabanında bulunan etiketlenmiş göz imgeleri, kapalı ve açık olarak iki etiketli KSA tabanlı modeller altında sınıflandırılmış ve başarımları test edilmiştir. Şekil 4'te açık ve kapalı göz imgelerine ait bazı örnekler görülmektedir.



**Şekil 4.** CEW veritabanında aynı kişilere ait açık ve kapalı göz imgelerinin bir kısmı(a: kapalı göz b: açık göz)

Şekil 4 incelediğinde, veritabanında aynı kişilere ait sol ve sağ gözlerin açık veya kapalı olduğu görülmektedir. Bu çalışmada, iki etiketli bir sınıflandırma yapılacağından açık göz imgeleri bir sınıfa, kapalı göz imgeleri de diğer bir sınıfa yerleştirilmiş ve hazırlanan verisetinin 80%'i eğitim, 20%'si test için kullanılmıştır. Yapılan bu çalışmanın başarımları Tablo 2'de görülmektedir.

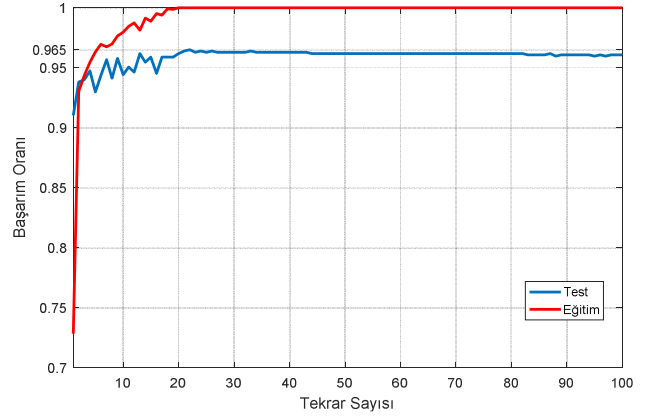
**Tablo 2.** KSA modellerinin 2 sınıfı tanımadaki başarımları

KSA Modelleri	Aşama (epoch) (100)	Her periyotta Geçen süre (sn) GPU/CPU	Başarım Oranı(%)
Lenet_5	94	1/5	95.98
<b>Vgg_5</b>	<b>98</b>	<b>1/5</b>	<b>96.49</b>
Vgg_6	88	1/6	96.19
Vgg-7	65	1/6	96.08
<b>Önerilen KSA Modeli</b>	<b>22</b>	<b>1/5</b>	<b>96.49</b>

Tablo 2 incelendiğinde, önerilen KSA modelinin sınıflandırma başarımının diğer KSA modellerine yakın sonuç verdiği görülmüştür. Aynı zamanda eğitim sürecinin GPU tabanlı işlemcilerde farklılıklar göstermediği, her deviri(epoch) 1 saniye gibi kısa bir sürede tamamladığı görülmüştür. Hazırlanan model en yüksek başarıya 22. devirde ulaşmış ve bu devirde de

modelin eğitim aşamasının tamamlandığı görülmüştür. Yapılan bu çalışmada, önerilen KSA modeli ile Vgg\_5 modelinin başarımlarının aynı olduğu fakat en yüksek başarıya ulaşma devrini incelendiğinde önerilen modelin daha iyi olduğu tespit edilmiştir. Şekil 5'te önerilen sınıflandırma modelinin başarımları görülmektedir.

Şekil 5 incelendiğinde, 22. devirde modelin 96.49% başarı elde ettiği ve bu aşamada eğitim aşamasının tamamlanmış olduğu görülmektedir. İncelenen diğer modellerin hem bu başarıya ulaşmadığı hem de eğitim aşamasının uzun sürdüğü görülmüştür. Tablo 3'te, literatürde aynı veri setini kullanan çalışmalar ile bu çalışmada önerilen KSA modelinin performans karşılaştırması verilmiştir.



**Şekil 5.** KSA modelinin iki sınıflı görüntüler üzerinde eğitim ve doğrulama sonuçları.

**Tablo 3.** Önerilen KSA modelinin literatürdeki çalışmalarla karşılaştırılması.

Çalışma	Veri seti (100)	Sınıflandırıcı	Başarım Oranı(%)
[10]	CEW	HPOG+SVM	95.90
[20]	ZJU	LBP+SVM	90.37
<b>Önerilen KSA Modeli</b>	<b>CEW</b>	<b>KSA</b>	<b>96.49</b>

Tablo 3 incelendiğinde, önerilen KSA modelinin CEW veritabanı ile yapılan çalışmaya [10] göre daha yüksek başarımlar elde ettiği görülmüştür. Literatürdeki bu çalışmalarda, verilere ait birçok dönüşümden sonra elde edilen özellik vektörleri üzerinde DVM sınıflandırıcıları kullanılmıştır. Bu çalışmada ise herhangi bir ön işlem, özellik çıkarımı aşaması olmadan verilerin sınıflandırılması sağlanmıştır. Aynı zamanda, elde edilen sınıflandırma doğruluğu literatürdeki diğer yapılar göre yüksektir.

#### V. SONUÇLAR

Bu çalışmada, sürüş ortamında sürücü uykuluk tespiti için KSA tabanlı bir derin öğrenme modeli önerilmiştir. Önerilen modelin literatürdeki incelenen yöntemlere göre daha iyi bir sonuç ürettiği görülmüştür. Ayrıca önerilen yöntem, KSA alanında oldukça popüler olan Lenet ve Vgg gibi modellerle kıyaslandığında hazırlanan modelin başarımlarının yüksek çıktığı görülmüştür. Bu model, sürücülerin araç kullanımında gözlerine odaklanarak, gözlerin açık ya da kapalı olup olmadıklarını belirleyebilir. Önerilen bu model sürücü destek sistemi için

avantaj sağlayan bir çalışma olarak değerlendirilebilir. Aynı zamanda, insan-bilgisayar arayüz tasarımı ve yüz ifadesi tanıma gibi alanlarda kullanılabilir. Önerilen modelin, görüntüleri önışlemeden geçirilmeden doğrudan işlemleri, hem zaman hem de maliyet açısından incelenen diğer modellerden daha iyi sonuç ürettiği tespit edilmiştir. İleriki çalışmalarda sürücünün sadece göz görüntüleri değil aynı zamanda hareketleri, ses sinyalleri, yüz ifadeleri ve EEG sinyalleri de alınarak farklı yöntemlerin kullanılması hedeflenmektedir.

## KAYNAKÇA

- [1] R. Dale, A. Stedmon. "To Delegate or not to Delegate: A Review of Control Frameworks for Autonomous Cars." *Applied ergonomics*, vol:53 383-388, 2016.
- [2] İ.H. Hancı, ve B. Eşiyok, "Uyku ve Trafik Kazaları", <http://www.ttb.org.tr/STED/sted0301/1.html>, 10 Mart 2014.
- [3] Türkiye İstatistik Kurumu (TÜİK), İnternet Erişimi: <http://www.tuik.gov.tr/PreHaberBultenleri.do?id=24606> Erişim tarihi: 27.02.2018.
- [4] NCSDR/NHTSA Expert Panel on Driver Fatigue and Sleepiness, "Drowsy driving and automobile crashes," NHTSA report. İnternetErişimi: <https://www.nhtsa.gov/sites/nhtsa.dot.gov/files/808707.pdf> Erişim Trihi: 27.02.2018
- [5] R.P. Nikhil, C. K. Chien-Yao, L.W., Chao, C.F., Jung, T.P., Liang S.F. and Lin, C.T., 2008. "EEG-based Subject-and Session-independent Drowsiness Detection: An Unsupervised Approach," *EURASIP Journal on Advances in Signal Processing*, ISSN: 1110-8657, January 2008.
- [6] Y. Takei, and Y. Furukawa, 2005. "Estimate of driver's fatigue through steering motion". *Man and Cybernetics IEEE International Conference*, vol. 2, pp.1765- 1770, 2005
- [7] S. Golgiyar, A. F. Kocamaz, F. Okumuş, "Video Tabanlı Uykulu Sürücü Algılama Sistemi", *Eleco 2014 Elektrik – Elektronik – Bilgisayar ve Biyomedikal Mühendisliği Sempozyumu*, s.332-338, 2014.
- [8] S. Vitabile, A. De Paola, and D. Sorbello, "A realtime non-intrusive FPGA-based drowsiness detection system", *Journal of Ambient Intelligence and Humanized Computing*, vol. 2, no. 4, pp 251-262, 2011.
- [9] L.M. BERGASA, et al. Real-time system for monitoring driver vigilance. *IEEE Transactions on Intelligent Transportation Systems*, 7.1: 63-77, 2006.
- [10] F., Song, et al. "Eyes closeness detection from still images with multi-scale histograms of principal oriented gradients." *Pattern Recognition* 47.9: 2825-2838, 2014.
- [11] B. Bhowmick, and KS Chidanand Kumar. "Detection and classification of eye state in IR camera for driver drowsiness identification." *Signal and Image Processing Applications (ICSIPA), IEEE International Conference on. IEEE*, 2009.
- [12] L. Xue, X. Tan, and S. Chen. "Eyes closeness detection using appearance based methods." *International Conference on Intelligent Information Processing. Springer, Berlin, Heidelberg*, 2012.
- [13] J. Gehring, Y. Miao, F. Metze, "Extracting Deep Bottleneck Features Using Stacked Auto-Encoders", *Acoustics, Speech and Signal Processing (ICASSP), IEEE International Conference on May* 2013.
- [14] Y. LeCun, "LeNet-5, convolutional neural networks," 2013
- [15] A. Krizhevsky, I. Sutskever, E. Geoffrey Hinton, "Imagenet Classification With Deep Convolutional Neural Networks", *Advances in Neural Information Processing Systems*, pp. 1097-1105, 2012.
- [16] S. Christian, "Going Deeper With Convolutions." *Proceedings Of The IEEE Conference on Computer Vision and Pattern Recognition*, P. 1-9, 2015.
- [17] İnternet Erişimi: [http://www.robots.ox.ac.uk/~vgg/research/very\\_deep](http://www.robots.ox.ac.uk/~vgg/research/very_deep) Erişim tarihi: 27.02.2018
- [18] He, Kaiming, "Deep Residual Learning for Image Recognition." *Proceedings of the IEEE conference on computer vision and pattern recognition.*, p. 770-778, 2016.
- [19] Closed Eyes In The Wild (CEW) Dataset. İnternet Erişimi: <http://parnec.nuaa.edu.cn/xtan/data/ClosedEyeDatabases.html> Erişim Tarihi: 27.02.2018
- [20] Wu, Yu-Shan, et al. "An eye state recognition method for drowsiness detection." *Vehicular technology conference (VTC 2010-Spring), 2010 IEEE 71st. IEEE*, 2010